

Cadenas de markov

Material de lectura



1. INTRODUCCIÓN

Las Cadenas de Markov son un concepto fundamental en el campo de la investigación de operaciones y la teoría de probabilidades, que se utilizan para modelar sistemas estocásticos donde el futuro estado del sistema depende únicamente del estado actual y no de los eventos previos.

2. ESTRUCTURA DE CONTENIDOS

1. Características y definición.
2. Diagrama de estados y matriz de transición.
3. Características del estado estable.
4. Características del estado absorbente.

3. DESARROLLO DE CONTENIDOS

1. Características y definición

Las Cadenas de Markov son modelos probabilísticos que describen un sistema en el cual el estado futuro depende únicamente del estado actual, es decir, no tienen "memoria" de los estados anteriores. Este tipo de modelos se utilizan para predecir cómo un sistema cambia entre diferentes estados en función de probabilidades de transición definidas entre dichos estados. Estas probabilidades se organizan en una matriz de transición que guía la evolución del sistema en el tiempo. Las Cadenas de Markov son aplicables en una variedad de campos como logística, finanzas, biología, telecomunicaciones, entre otros.

$$P(X_{n+1} = S_j | X_n = S_i, X_{n-1}, \dots, X_0) = P(X_{n+1} = S_j | X_n = S_i)$$

Donde:

- X_n representa el estado del sistema en el tiempo n .
- S_i y S_j son estados del sistema.
- La probabilidad de transición de S_i a S_j está determinada únicamente por el estado actual $X_n = S_i$.

Características principales:

- Memoria limitada: La probabilidad de transición al siguiente estado depende únicamente del estado actual, no de los estados anteriores.
- Estados: Representan las posibles condiciones del sistema.
- Probabilidades de transición: Matriz que indica la probabilidad de moverse de un estado a otro.

2. Diagrama de Estados y Matriz de Transición

El diagrama de estados es una representación gráfica de una Cadena de Markov, donde los círculos representan los estados y las flechas indican las transiciones entre ellos, etiquetadas con las



probabilidades correspondientes. La matriz de transición organiza estas probabilidades en una tabla, donde cada fila y columna representa un estado y cada celda contiene la probabilidad de transición entre los estados.

Ejemplo en Logística: En un sistema de gestión de inventarios, los estados pueden representar diferentes niveles de stock, y las probabilidades de transición modelan la probabilidad de que un cierto número de productos sean consumidos o repuestos. La matriz de transición permitiría prever cuándo el inventario llegará a niveles críticos y cuándo será necesario hacer un nuevo pedido.

Ejemplo en Telecomunicaciones: En el ruteo de llamadas, los estados representan nodos en una red de telecomunicaciones, y las probabilidades de transición modelan las probabilidades de que una llamada pase de un nodo a otro, optimizando el ruteo y minimizando el riesgo de sobrecarga.

Ejemplo en Biología: En genética, las cadenas de Markov pueden modelar cómo las secuencias de ADN evolucionan con el tiempo. Cada estado podría representar una secuencia de bases, y las probabilidades de transición modelarían las tasas de mutación de una base a otra.

3. Estado Estable

El estado estable se alcanza cuando la distribución de probabilidades entre los diferentes estados no cambia más con el tiempo, es decir, el sistema ha llegado a un equilibrio. Este concepto es útil en muchas aplicaciones, pues permite analizar el comportamiento a largo plazo de un sistema.

Ejemplo en Finanzas: En el análisis de riesgo, un modelo de Markov puede predecir cómo un portafolio de inversiones pasará por diferentes estados de rentabilidad o pérdida. El estado estable indicaría una distribución a largo plazo de los posibles resultados financieros.

Ejemplo en Marketing: Las Cadenas de Markov pueden usarse para modelar el comportamiento del consumidor en cuanto a su lealtad a marcas. Un estado estable mostraría la proporción de clientes que permanecerán fieles a una marca específica o se moverán a la competencia.

4. Estado Absorbente

Un estado absorbente es aquel que, una vez alcanzado, no se puede abandonar. Esto es útil en sistemas donde ciertos estados representan un fin definitivo del proceso.

Ejemplo en Sistemas de Transporte: En modelos de tráfico, un estado absorbente podría representar la llegada a un destino final, como una estación de autobuses o una terminal de aeropuerto. El análisis permite calcular el tiempo promedio para alcanzar estos estados absorbentes desde diferentes puntos de origen.

Ejemplo en Atención Médica: En la modelización de sistemas de salud, los estados absorbentes podrían representar la recuperación completa de un paciente o la necesidad de atención permanente, permitiendo una planificación más precisa de recursos médicos.

Aplicaciones por Sector

1. Logística:
 - Modelos de inventarios: Optimización de los niveles de stock y predicción de demanda.
 - Cadenas de suministro: Modelización de la distribución de productos a través de diferentes centros logísticos.
2. Telecomunicaciones:
 - Ruteo de llamadas: Optimización de la transferencia de datos a través de diferentes nodos en una red.
 - Tráfico de datos: Predecir la sobrecarga en ciertas partes de la red.
3. Finanzas:
 - Modelos de riesgo: Evaluación de la probabilidad de que un activo o portafolio pase de un estado rentable a uno de pérdida.
 - Análisis de mercado: Predicción de los cambios en la participación de mercado o en las tasas de interés.
4. Sistemas de Transporte:
 - Modelos de tránsito: Simulación de flujos de tráfico y predicción de congestiones.
 - Optimización de rutas: Identificación de las rutas más eficientes para minimizar tiempos de viaje.
5. Biología y Epidemiología:
 - Propagación de enfermedades: Modelar la transición de individuos sanos a infectados y recuperados en poblaciones.
 - Genética: Simulación de la evolución genética a lo largo de generaciones.
6. Ciencias de la Computación:
 - Machine Learning: Utilización de las Cadenas de Markov en algoritmos como los modelos ocultos de Markov (HMM) para procesamiento de lenguaje natural.
 - Procesamiento de datos: Predicción de la siguiente acción de un usuario en un sistema basado en su historial.
7. Marketing:
 - Comportamiento del consumidor: Modelización de la transición entre diferentes estados de lealtad del cliente, como nuevos clientes, clientes frecuentes o desertores.


Ejemplo

El departamento de estudios de mercado de una fábrica estima que el 40% de la gente que compra un producto un mes, no lo comprará el mes siguiente. Además, el 20% de quienes no lo compran un mes lo adquirirá al mes siguiente. En una población de 1000 individuos, 100 compraron el producto el primer mes. ¿Cuántos lo comprarán al mes próximo? ¿Y dentro de dos meses?

Solución:

Para resolver este tipo de problemas, lo primero es hacer un esquema. A la vista del esquema podemos pasar a construir la matriz de probabilidades de transición:





Del 100% de clientes que compra en un mes un producto el 40% no compra el mes siguiente, o sea el 60% lo sigue comprando el siguiente mes.

Del 100% de clientes que quienes no lo compran en un mes, solo el 20% lo adquieren el mes siguiente. O sea, el 80% no lo compran el siguiente mes.

Cálculo: con esa información construimos la matriz 2x2. P(0) representa la situación:

$$P_0 = \begin{pmatrix} .6 & .4 \\ .2 & .8 \end{pmatrix}$$

$$C \ N = (100 \ 900) * \begin{pmatrix} .6 & .4 \\ .2 & .8 \end{pmatrix} = (240, 760)$$

El primer mes comprarán C=240 y no comprarán N=760 personas

$$P_0 = \begin{pmatrix} .6 & .4 \\ .2 & .8 \end{pmatrix} \begin{pmatrix} .6 & .4 \\ .2 & .8 \end{pmatrix} = \begin{pmatrix} .44 & .56 \\ .28 & .96 \end{pmatrix}$$

$$C \ N = (100 \ 900) * \begin{pmatrix} .44 & .56 \\ .28 & .96 \end{pmatrix} = (296, 920)$$

El segundo mes comprarán C=296 y No comprarán N= 920 personas

Las Cadenas de Markov son herramientas poderosas para modelar sistemas estocásticos en los que el futuro depende únicamente del estado presente. Su aplicabilidad en diversos sectores, desde la logística hasta la biología, demuestra su versatilidad en la toma de decisiones bajo incertidumbre. Estas cadenas permiten predecir comportamientos a largo plazo, optimizar procesos y entender mejor la dinámica de sistemas complejos en distintas industrias.

4. Bibliografías

- Hillier, F. S., & Lieberman, G. J. (2017). *Introducción a la investigación de operaciones* (11ª ed.). McGraw-Hill Interamericana.
- Hernández Sampieri, R. (2014). *Fundamentos de Investigación*. McGraw-Hill Interamericana.
- Jacobs, F. R., & Chase, R. B. (2020). *Administración de operaciones* (16ª ed.). McGraw-Hill Interamericana.



- Palacios Figueroa, R. (2017). *Investigación de Operaciones I: Programación Lineal*.
- Kong, M. (2013). *Investigación de operaciones: programación lineal. Problemas de transporte. Análisis de redes*. Fondo Editorial de la Pontificia Universidad Católica del Perú.
- Gómez Gómez, I., & Brito Aguilar, J. G. (2020). *Administración de Operaciones*. Universidad Internacional del Ecuador.
- Urrosolo Muñoz, J., & Antón Garmendia, U. (2021). *Gestión administrativa del transporte y la logística*. Paraninfo.

